

Projet Supply Chain

*Analyse automatique des avis clients pour
optimiser la satisfaction*

Equipe:
Laurène ATTIA
Ilan SARFATI
Walid MATALLAH

15/06/2025

Sommaire

- 1. Contexte & Objectifs
- 2. Analyse exploratoire des données
- 3. Modélisation
- 4. Optimisation
- 5. Démonstration Streamlit
- 6. Conclusion & Perspectives



1. Contexte & Objectifs

Contexte

- La **Supply Chain** regroupe toutes les étapes de la fabrication à la livraison d'un produit.
- La **satisfaction client** est un enjeu clé, souvent exprimée dans les avis en ligne (Trustpilot, sites distributeurs, réseaux sociaux).

Objectifs

- **Exploiter les avis clients** pour mieux comprendre leur satisfaction.
- Créer des **outils automatiques pour analyser et prédire la note client (1 à 5 étoiles)**.
- Identifier les entités importantes (marques, lieux..).
- Extraire les thèmes fréquents (livraison, défaut produit).



2. Analyse exploratoire des données

Données utilisées

- **Source:** Trustpilot & Trusted Shops
- **Entreprises:** Veepee & ShowRoom
- **19 863 avis, 11 variables**
- **Cible:** note de satisfaction (1 à 5 étoiles)
- **Variables clés:** commentaire client, entreprise, plateforme
- **Dataset complet:** fichier [trust.csv](#)





figure 1: Histogramme illustrant la répartition des données
au sein du dataset

Exploration & préparation des données

- **Nettoyage des données:** conversion des dates, suppression des variables inutiles ou trop incomplètes (**client, ville, réponses**).
- **Encodage One-Hot** des variables catégorielles (**company, source**).
- **Traitement du texte:** passage en minuscules, suppression de la ponctuation et des stopwords.
- Création d'une **nouvelle colonne « Commentaire_clean »**.
- **Suppression des commentaires vides** et de la colonne **« reponse »** (57% manquantes).

Matrice de corrélation entre variables temporelles et star



Analyse

- **Faible corrélation globale** avec la note.
- Seule la variable **commande_weekend** (corr. ≈ 0.16) est conservée.
- **Suppression des variables horaires:** trop incomplètes et peu informatives.

figure 2: Etude de corrélation entre les variables temporelles et la variable cible

Distribution des Notes de Satisfaction




figure 3: Distribution de la variable cible (star)

Analyse

Distribution fortement **déséquilibrée**:

- ★★★★★: ~ 40 % des avis
- ★: ~ 26 %
- **Classes intermédiaires sous représentées**, rendant la prédiction difficile.
- **Action**: regroupement des notes pour améliorer la robustesse des modèles.




figure 4: Word Cloud des avis - 10 mots les plus fréquents

Analyse

- Fréquence élevée de mots liés au **produit**, à la **livraison** et au **service client**.
- **Termes positifs:** "très", "bien"
- **Termes négatifs:** "remboursement", "rien"
- Révèle une **polarisation**, en phase avec la distribution des notes.

	Variable	Description
0	Commentaire	Avis textuel du client
1	star	Note de satisfaction (1 à 5)
2	commande_weekend	Commande passée un week-end (0/1)
3	company_ShowRoom	Entreprise ShowRoom (One-Hot)
4	company_VeePee	Entreprise VeePee (One-Hot)
5	source_TrustPilot	Plateforme TrustPilot (One-Hot)
6	source_TrustedShop	Plateforme Trusted Shops (One-Hot)
7	Commentaire_clean	Commentaire nettoyé pour analyse textuelle

figure 5: Variables finales retenues pour la modélisation

3. Modélisation

The background of the slide is a blue gradient, transitioning from a darker blue on the left to a lighter blue on the right. Overlaid on this gradient are several abstract geometric patterns. These patterns consist of white lines connecting small white dots, forming a network of interconnected triangles and polygons. Some of these shapes are more prominent and detailed, while others are fainter and more sparse, creating a sense of depth and complexity. The overall aesthetic is modern and technological.

Objectif

- Prédire la note client (1-5 étoiles) à partir des avis textuels nettoyés.

Méthodologie

- Split train/test (80/20) stratifié sur la note.
- Vectorisation TF-IDF & suppression des stopwords.
- Rééquilibrage des classes avec SMOTE et ADASYN.




figure 6: Distribution des classes avant/après application de SMOTE

Modèles testés

- Logistic Regression
- Multinomial Naive Bayes
- Linear SVC
- Random Forest
- Gradient Boosting
- K-Nearest Neighbors

Evaluation des modèles

- Métriques: accuracy, précision, rappel, F1-macro.
- Fonction automatisée d'entraînement et d'évaluation.

	Model	Accuracy	Macro Precision	Macro Recall	Macro F1-score
0	LogisticRegression	0.612554	0.492135	0.507653	0.494715
1	MultinomialNB	0.615831	0.485208	0.498074	0.485565
2	LinearSVC	0.612049	0.481134	0.492365	0.484038
3	RandomForestClassifier	0.644064	0.490936	0.484865	0.480087
4	GradientBoostingClassifier	0.570456	0.463841	0.459783	0.458935
5	KNeighborsClassifier	0.414923	0.434085	0.394636	0.370487

figure 7: Tableau comparatif des performances

Résultats & Limites

- **Logistic Regression** et **MultinomialNB** présentent les **meilleurs scores F1** (~0.49), illustrant une bonne gestion du déséquilibre.
- **Random Forest** se distingue par la **meilleure précision globale (64.4%)**.
- Les **classes extrêmes sont bien identifiées** mais les intermédiaires restent difficiles à prédire.
- **SMOTE améliore l'équilibre, mais d'autres méthodes sont nécessaires:** regroupement des classes, NER, optimisation des paramètres.




figure 7: Matrice de confusion du modèle Random Forest

3. Optimisation

The background of the slide is a blue gradient, transitioning from a darker blue on the left to a lighter blue on the right. Overlaid on this gradient is a complex network of white lines and dots. These lines and dots form various geometric shapes, including triangles and polygons, which are interconnected to create a larger, abstract structure. The lines are thin and white, while the dots are small white circles. The overall effect is a modern, technical, and geometric aesthetic.

Améliorations apportées

- Regroupement des classes + SMOTE
- Optimisation par Grid Search
- Enrichissement textuel par Reconnaissance d'Entités Nommées (NER)

Regroupement des classes + SMOTE

	Model	Accuracy	Macro Precision	Macro Recall	Macro F1-score	Rééquilibrage
0	RandomForestClassifier	0.815478	0.736684	0.754647	0.744657	SMOTE + regroupement
1	LogisticRegression	0.796824	0.729859	0.769376	0.741880	SMOTE + regroupement
2	MultinomialNB	0.788757	0.720793	0.765464	0.734443	SMOTE + regroupement
3	LinearSVC	0.791278	0.714831	0.744814	0.725545	SMOTE + regroupement
4	GradientBoostingClassifier	0.715906	0.699235	0.721605	0.683381	SMOTE + regroupement
5	KNeighborsClassifier	0.588606	0.653217	0.636975	0.576524	SMOTE + regroupement

figure 8: Tableau comparatif des performances des modèles après regroupement + SMOTE

Optimisation par Grid Search

- **Recherche aléatoire d'hyper paramètres** sur 20% du train.
- **Modèles sélectionnés:** Logistic Regression, Linear SVC, Random Forest.
- **Objectif:** maximiser F1-macro.
- **Scores:** LR 0.68, SVC 0.67, RF 0.61
- **Améliore la généralisation**, mais ne remplace pas le rééquilibrage.




figure 9: Matrice de confusion - Logistic Regression optimisée

Enrichissement par NER

- **Extraction d'entités avec spaCy.**
- **Ajout des entités** au texte nettoyé.
- **Pipeline: regroupement classes + SMOTE + NER.**
- **Résultats:** amélioration sur classe intermédiaire (2).
- Impact positif mais **secondaire par rapport à SMOTE + regroupement.**

```

=== Résultats FINAUX avec NER (entités) + regroupement de classes + SMOTE ===
      Model Accuracy Macro Precision Macro Recall \
0      LogisticRegression 0.798336      0.730672      0.769574
3      RandomForestClassifier 0.813461      0.732906      0.749955
1      MultinomialNB 0.787245      0.719363      0.763690
2      LinearSVC 0.791530      0.714053      0.741329
4      GradientBoostingClassifier 0.720192      0.700718      0.725097
5      KNeighborsClassifier 0.594656      0.652141      0.647147

Macro F1-score
0      0.742832
3      0.740408
1      0.732790
2      0.724160
4      0.686843
5      0.583014

```

figure 10: Tableau comparatif des performances des modèles après méthode NER



4. Démonstration Streamlit



5. Conclusion & perspectives

Conclusion

- Meilleur modèle: RandomForest + SMOTE + Regroupement des classes.
- Accuracy ~81.5%, F1-macro ~74.5%.
- Prédiction cohérente sur commentaires réels

Perspectives

- Explorer modèles deep learning (BERT, LSTM)
- Approfondir enrichissement sémantique (NER, autres techniques).
- Combiner SMOTE avec méthodes avancées de gestion du déséquilibre.

MERCI !